


Homework 1 Report - PM2.5 Prediction

學號：B05901043 系級：電機三 姓名：莊鎧爾


1. (1%) 請分別使用至少 **4** 種不同數值的 learning rate 進行 training（其他參數需一致），對其作圖，並且討論其收斂過程差異。

我將 Loss function 定義為 $Loss = \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{2 \times n}$


Training rate = 500




Training rate = 100



Training rate = 10



Training rate = 0.1



可以知道，**training rate** 介於 10 至 100 這個範圍時，會有比較快的收斂結果，尤其是 **training rate = 10** 時，不到 1000 次就幾乎要收斂到最小的 **loss**，而當 **training rate** 提高到 500 時，**gradient descent** 執行時會走的太大步，而走過最低點，因此收斂速度反而不如 **learning rate = 10** 和 100 時快，當 **training rate** 下降到 0.1 時，**gradient descent** 執行時每一次參數更新太少，所以收斂速度非常緩慢，但可以看到 **loss** 呈現穩定下降，因此只要等待的時間夠久，也可以走到最小值。

2. (1%) 請分別使用每筆 data9 小時內所有 feature 的一次項（含 bias 項）以及每筆 data9 小時內 PM2.5 的一次項（含 bias 項）進行 training，比較並討論這兩種模型的 root mean-square error（根據 kaggle 上的 public/private score）。

結果如下（根據 Kaggle public score）：

- i. 每筆 data9 小時內所有 feature 的一次項（含 bias 項）：9.49520
- ii. 每筆 data9 小時內 PM2.5 的一次項（含 bias 項）：9.56416

可以知道若只使用 PM2.5 的 data，資料量太少，得到的結果反而不如資料量多時好。

3. (1%)請分別使用至少四種不同數值的 regularization parameter λ 進行 training（其他參數需一至），討論及討論其 RMSE(traning, testing)（testing 根據 kaggle 上的 public/private score）以及參數 weight 的 L2 norm。

regularization parameter λ	0.1	1.0	10	50	100
RMSE (training)	22.87	22.89	23.01	24.53	25.88
RMSE (testing)	8.99193	9.65006	9.26648	9.23758	9.63401
Kaggle public score					
L2 norm	2.957×10^6	2.961×10^6	3.012×10^6	3.400×10^6	3.785×10^6

當 λ 變大時，training set 上表現的結果比較差，所以 RMSE 和 L2 norm 都比較差，但在 testing set 上，可以看到，若 λ 不要設太大，可以得到比較好的結果，但是如果設太大，反而過度的降低 weight，而在 testing set 上也表現的不好。

4.

(4-a)

let $\mathbf{X} = [\mathbf{x}_1 \ \mathbf{x}_2 \ \cdots \ \mathbf{x}_n]$, $\mathbf{t} = [t_1 \ t_2 \ \cdots \ t_n]^T$, $\mathbf{R} = [c_{ij}]$ where $c_{ij} = \begin{cases} 0 & \text{if } i \neq j \\ r_i & \text{if } i = j \end{cases}$

$$\text{Therefore, } E_D(\mathbf{w}) = \frac{1}{2} \sum_{n=1}^N r_n (t_n - \mathbf{w}^T \mathbf{x}_n)^2 = \frac{1}{2} (\mathbf{t} - \mathbf{X}^T \mathbf{w})^T \mathbf{R} (\mathbf{t} - \mathbf{X}^T \mathbf{w})$$

Find $\nabla_{\mathbf{w}} E_D(\mathbf{w})$

$$E_D(\mathbf{w} + \Delta \mathbf{w}) - E_D(\mathbf{w})$$

$$= \frac{1}{2} (\mathbf{t} - \mathbf{X}^T (\mathbf{w} + \Delta \mathbf{w}))^T \mathbf{R} (\mathbf{t} - \mathbf{X}^T (\mathbf{w} + \Delta \mathbf{w})) - \frac{1}{2} (\mathbf{t} - \mathbf{X}^T \mathbf{w})^T \mathbf{R} (\mathbf{t} - \mathbf{X}^T \mathbf{w})$$

$$= \frac{1}{2} [-(\mathbf{X}^T \Delta \mathbf{w})^T \mathbf{R} (\mathbf{t} - \mathbf{X}^T \mathbf{w}) - (\mathbf{t} - \mathbf{X}^T \mathbf{w})^T \mathbf{R} (\mathbf{X}^T \Delta \mathbf{w}) + (\mathbf{X}^T \Delta \mathbf{w})^T \mathbf{R} (\mathbf{X}^T \Delta \mathbf{w})]$$

$$= \frac{1}{2} [-2(\mathbf{X}^T \Delta \mathbf{w})^T \mathbf{R} (\mathbf{t} - \mathbf{X}^T \mathbf{w}) + (\mathbf{X}^T \Delta \mathbf{w})^T \mathbf{R} (\mathbf{X}^T \Delta \mathbf{w})]$$

$$= \frac{1}{2} \Delta \mathbf{w}^T [-2\mathbf{X}\mathbf{R}(\mathbf{t} - \mathbf{X}^T \mathbf{w}) + \mathbf{X}\mathbf{R}\mathbf{X}^T \Delta \mathbf{w}] \xrightarrow{\Delta \mathbf{w} \text{ is small}} -\Delta \mathbf{w}^T \mathbf{X}\mathbf{R}(\mathbf{t} - \mathbf{X}^T \mathbf{w})$$

$$\therefore \Delta \mathbf{w}^T \nabla_{\mathbf{w}} E_D(\mathbf{w}) = E_D(\mathbf{w} + \Delta \mathbf{w}) - E_D(\mathbf{w}) = -\Delta \mathbf{w}^T \mathbf{X}\mathbf{R}(\mathbf{t} - \mathbf{X}^T \mathbf{w})$$

$$\therefore \nabla_{\mathbf{w}} E_D(\mathbf{w}) = -\mathbf{X}\mathbf{R}(\mathbf{t} - \mathbf{X}^T \mathbf{w})$$

Find \mathbf{w}^* that minimizes $E_D(\mathbf{w})$, we solve $\nabla_{\mathbf{w}} E_D(\mathbf{w}^*) = -\mathbf{X}\mathbf{R}(\mathbf{t} - \mathbf{X}^T \mathbf{w}^*) = 0$

$$\mathbf{X}\mathbf{R}\mathbf{t} = \mathbf{X}\mathbf{R}\mathbf{X}^T \mathbf{w}^*$$

$$\mathbf{w}^* = (\mathbf{X}\mathbf{R}\mathbf{X}^T)^{-1}(\mathbf{X}\mathbf{R}\mathbf{t})$$

(4-b)

$$\mathbf{X} = \begin{bmatrix} 2 & 5 & 5 \\ 3 & 1 & 6 \end{bmatrix}, \mathbf{R} = \begin{bmatrix} 2 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 3 \end{bmatrix}, \mathbf{t} = \begin{bmatrix} 0 \\ 10 \\ 5 \end{bmatrix}$$

$$\mathbf{w}^* = (\mathbf{X}\mathbf{R}\mathbf{X}^T)^{-1}(\mathbf{X}\mathbf{R}\mathbf{t}) = \begin{bmatrix} 2.283 \\ -1.136 \end{bmatrix}$$

5.

Because the syntax in question is misleading, I let

$$y(\mathbf{x}_n, \mathbf{w}) = w_0 + \sum_{i=1}^D w_i x_i^n$$

Now, I define E averaged over the noise distribution is E'

$$\begin{aligned} E'(\mathbf{w}) &= \frac{1}{2} \sum_{n=1}^N (y(\mathbf{x}_n', \mathbf{w}) - t_n)^2 = \frac{1}{2} \sum_{n=1}^N \left(w_0 + \sum_{i=1}^D w_i (x_i^n + \epsilon_i^n) - t_n \right)^2 \\ &= \frac{1}{2} \sum_{n=1}^N \left(\left(w_0 + \sum_{i=1}^D w_i x_i^n - t_n \right) + \sum_{i=1}^D w_i \epsilon_i^n \right)^2 \\ &= \frac{1}{2} \sum_{n=1}^N \left(w_0 + \sum_{i=1}^D w_i x_i^n - t_n \right)^2 + \sum_{n=1}^N \left[\left(w_0 + \sum_{i=1}^D w_i x_i^n - t_n \right) \left(\sum_{i=1}^D w_i \epsilon_i^n \right) \right] \\ &\quad + \frac{1}{2} \sum_{n=1}^N \left(\sum_{i=1}^D w_i \epsilon_i^n \right)^2 \\ &= E(\mathbf{w}) + \sum_{n=1}^N \left[(y(\mathbf{x}_n, \mathbf{w}) - t_n) \left(\sum_{i=1}^D w_i \epsilon_i^n \right) \right] + \frac{1}{2} \sum_{n=1}^N \left(\sum_{i=1}^D w_i \epsilon_i^n \right)^2 \end{aligned}$$

Because of $\mathbb{E}[\epsilon_i \epsilon_j] = \delta_{ij} \sigma^2$ and $\mathbb{E}[\epsilon_i] = 0$, we know $\sum_{n=1}^N \epsilon_i \epsilon_j = \delta_{ij} N \sigma^2$ and $\sum_{n=1}^N \epsilon_j = 0$

$$\sum_{n=1}^N \left[(y(\mathbf{x}_n, \mathbf{w}) - t_n) \left(\sum_{i=1}^D w_i \epsilon_i^n \right) \right] = 0$$

$$\sum_{n=1}^N \left(\sum_{i=1}^D w_i \epsilon_i^n \right)^2 = \sum_{n=1}^N \sum_{i=1}^D (w_i \epsilon_i)^2 = N \sigma^2 \sum_{i=1}^D w_i^2$$

Therefore,

$$E'(\mathbf{w}) = E(\mathbf{w}) + N \sigma^2 \sum_{i=1}^D w_i^2$$

The noise distribution is equivalent to sum-of-squares error for noise-free input variables with the addition of a weight -decay regularization term, in which the bias parameter w_0 is omitted.

6.

Let \mathbf{A} with eigenvalue $\lambda_1, \lambda_2, \dots, \lambda_n$, then

Because $\det(\mathbf{A}) = \prod_{i=1}^n \lambda_i$

$$\frac{d}{d\alpha} \ln(|\mathbf{A}|) = \frac{d}{d\alpha} \ln \left(\prod_{i=1}^n \lambda_i \right) = \frac{d}{d\alpha} \sum_{i=1}^n \ln(\lambda_i) = \sum_{i=1}^n \frac{d}{d\alpha} \ln(\lambda_i) = \sum_{i=1}^n \frac{1}{\lambda_i} \frac{d}{d\alpha} \lambda_i$$

And we know that

$$\mathbf{A}^{-1} \text{ with eigenvalue } \frac{1}{\lambda_1}, \frac{1}{\lambda_2}, \dots, \frac{1}{\lambda_n}$$

$$\frac{d}{d\alpha} \mathbf{A} \text{ with eigenvalue } \frac{d}{d\alpha} \lambda_1, \frac{d}{d\alpha} \lambda_2, \dots, \frac{d}{d\alpha} \lambda_n$$

$$\mathbf{A}^{-1} \frac{d}{d\alpha} \mathbf{A} \text{ with eigenvalue } \frac{1}{\lambda_1} \frac{d}{d\alpha} \lambda_1, \frac{1}{\lambda_2} \frac{d}{d\alpha} \lambda_2, \dots, \frac{1}{\lambda_n} \frac{d}{d\alpha} \lambda_n$$

Because $\text{trace}(\mathbf{A}) = \sum_{i=1}^n \lambda_i$

$$\text{Tr} \left(\mathbf{A}^{-1} \frac{d}{d\alpha} \mathbf{A} \right) = \sum_{i=1}^n \frac{1}{\lambda_i} \frac{d}{d\alpha} \lambda_i$$

Therefore,

$$\frac{d}{d\alpha} \ln(|\mathbf{A}|) = \text{Tr} \left(\mathbf{A}^{-1} \frac{d}{d\alpha} \mathbf{A} \right)$$